



Cos'è Apache Spark

Programmazione

Apache Spark è un framework open-source per l'elaborazione distribuita dei dati, progettato per gestire in modo estremamente rapido grandi volumi di informazioni su cluster di macchine.

Nasce come evoluzione del modello MapReduce di Hadoop, migliorandone drasticamente le prestazioni grazie all'uso massiccio della memoria RAM: invece di scrivere continuamente su disco tra un'operazione e l'altra, Spark conserva i dati in memoria, riducendo la latenza e rendendo possibile l'analisi interattiva, il machine learning e lo streaming in tempo reale.

La sua architettura si basa su un driver che coordina il lavoro e su più executor che processano i dati in parallelo, distribuendo automaticamente il carico e gestendo la tolleranza ai guasti.



Dal punto di vista funzionale, Spark fornisce un ecosistema completo per diverse tipologie di workload.

Spark SQL permette di interrogare dati strutturati con un linguaggio simile all'SQL; MLlib offre algoritmi di machine learning scalabili; GraphX consente l'elaborazione di grafi complessi; e Spark Streaming (oggi Structured Streaming) consente di processare flussi continui di dati in near real-time.

Grazie alla sua flessibilità, al supporto per linguaggi come Python, Scala, Java e R, e alla possibilità di integrazione con sistemi come Hadoop HDFS, S3, Kafka e molti altri, Spark è diventato uno degli strumenti principali nel panorama Big Data per analisi veloci, scalabili e distribuite.



- **In-memory Computing**

Spark elabora i dati direttamente in RAM, evitando continui accessi al disco come accade in Hadoop MapReduce.

Questo approccio riduce drasticamente la latenza e permette performance anche 100 volte superiori su workload complessi.

I dati vengono memorizzati in strutture distribuite (RDD o DataFrame) che possono essere riutilizzate senza ricalcoli inutili.



- **RDD (Resilient Distributed Dataset) e DataFrame**

Spark si basa su due modelli di dati:

- **RDD: collezioni distribuite immutabili, tolleranti ai guasti e processate in parallelo. Sono concettualmente simili a liste distribuite su cluster.**
- **DataFrame e Dataset: livello più alto, ottimizzato grazie a Catalyst (optimizer interno) e a una struttura tabellare simile a SQL.**

Questo consente sia controllo fine (RDD) sia ottimizzazioni automatiche (DataFrame/Dataset).



- **Lazy Evaluation**

Le trasformazioni applicate ai dataset (es. map, filter, select) non vengono eseguite subito.

Spark costruisce una pipeline logica delle operazioni e le esegue solo quando necessario, cioè quando viene invocata un'azione (es. collect, count, show).

Questo permette di ottimizzare l'esecuzione e ridurre i passaggi non necessari.



- **DAG Scheduler**

Spark costruisce un Directed Acyclic Graph (DAG) per descrivere la sequenza di operazioni.

Il DAG Scheduler suddivide il lavoro in task paralleli, li raggruppa in stage e li assegna ai nodi del cluster, ottimizzando:

- **parallelismo**
- **località dei dati**
- **recupero dai guasti**

È il cuore del sistema di esecuzione distribuita.



- **Tolleranza ai Guasti**

Gli RDD sono resilienti: Spark riesce a ricostruire le partizioni perse usando la lineage (il “ciclo di vita” delle operazioni che li hanno generati).

Se un nodo del cluster fallisce, Spark ricalcola solo la parte danneggiata, garantendo continuità.



- **Cluster Manager Multipli**

Spark può lavorare con diversi sistemi di gestione del cluster:

- **Standalone (nativo Spark)**
- **YARN (Hadoop)**
- **Mesos**
- **Kubernetes**

Questa compatibilità lo rende facilmente adottabile in contesti diversi.



- **API Multi-Lingua**

Spark supporta ufficialmente:

- **Scala (linguaggio nativo)**
- **Python (PySpark)**
- **Java**
- **R**

Questo permette l'integrazione in progetti molto diversi, dal data engineering al machine learning.



- **Componenti Integrati**

Spark non è solo un motore di calcolo, ma un ecosistema completo:

- **Spark SQL: query SQL su DataFrame, gestione tabelle e cataloghi.**
- **MLlib: libreria di machine learning scalabile.**
- **GraphX: analisi e algoritmi su grafi.**
- **Structured Streaming: stream processing in near real-time.**

Tutto utilizza lo stesso motore, semplificando pipelines dati complesse.



Caratteristica	Descrizione Tecnica
In-memory Computing	L’elaborazione avviene prevalentemente in RAM, riducendo la latenza rispetto ai sistemi basati su disco ed accelerando analisi iterative o complesse.
RDD e DataFrame	RDD: dataset distribuiti immutabili, tolleranti ai guasti. DataFrame/Dataset: API ottimizzate con struttura tabellare per elaborazioni più efficienti e dichiarative.
Lazy Evaluation	Le trasformazioni vengono accumulate e valutate solo al momento di un’azione, permettendo ottimizzazioni dell’intera pipeline.
DAG Scheduler	Spark costruisce un grafo aciclico (DAG) delle operazioni, suddivide il lavoro in stage e task e li distribuisce sui nodi del cluster.
Tolleranza ai Guasti	Ricostruzione automatica delle partizioni perse tramite lineage degli RDD; ricalcolo solo delle parti coinvolte nel guasto.
Cluster Manager Multipli	Supporto per Standalone, YARN, Mesos e Kubernetes, permettendo l'esecuzione in ambienti diversi con piena portabilità.
API Multi-lingua	Supporto nativo per Scala, Python (PySpark), Java e R, integrabili in flussi ETL, machine learning e applicazioni distribuite.
Componenti Integrati	Moduli come Spark SQL, MLlib, GraphX e Structured Streaming che coprono query, ML, grafi e stream processing usando lo stesso motore.
Scalabilità Orizzontale	Possibilità di aumentare capacità e performance aggiungendo nodi, con bilanciamento automatico del carico e parallelismo efficiente.



Guida Installazione Apache Spark

- **Installa Java (obbligatorio)**

Vai sul sito Adoptium, scarica e installa una versione di Java 8 o superiore.

Dopo l'installazione, verifica il comando `java -version` per assicurarti che Java sia visibile nel sistema.

- **Installa Python (se vuoi usare PySpark)**

Se intendi lavorare con PySpark, installa Python dal sito ufficiale.

Controlla l'installazione con `python --version`.

- **Scarica Apache Spark**

Vai alla pagina ufficiale di download di Apache Spark.

Scegli una versione stabile e scarica il pacchetto “Pre-built for Apache Hadoop”.

Estrai il contenuto in una cartella del tuo sistema (ad esempio `C:\spark` su Windows oppure `/opt/spark` su macOS/Linux).

- **Aggiungi Spark al PATH**

Inserisci le cartelle `bin` e `sbin` del tuo Spark nelle variabili d'ambiente `PATH`, così da poter usare i comandi Spark da terminale.

Su Windows modifica le variabili d'ambiente; su macOS/Linux aggiungi le righe necessarie al tuo file `.bashrc` o `.zshrc`.

- **(Solo Windows) Installa winutils.exe**

Spark su Windows richiede `winutils.exe` per simulare alcune funzioni di Hadoop.

Scaricalo dalla repo dedicata, creane una cartella (ad esempio `C:\hadoop\bin\`) e aggiungi la variabile d'ambiente `HADOOP_HOME`, indicando la cartella principale.

- **Verifica l'installazione**

Apri il terminale e lancia i comandi `spark-shell` per la shell Scala e `pyspark` per PySpark.

Se la console si avvia senza errori, Spark è correttamente installato.

- **Esegui un test minimo**

Avvia `pyspark` e prova a creare una semplice sessione Spark e un `DataFrame`.

Se il comando `df.show()` restituisce un output, Spark è operativo.



Spiegazione

- **parallelize** crea un RDD distribuendo i dati sul cluster.
- **map** è una trasformazione: Spark costruisce il DAG ma non esegue ancora nulla.
- **filter** è un'altra trasformazione che filtra i valori.
- **collect** è un'azione: obbliga Spark a eseguire davvero tutta la pipeline e restituisce i risultati al driver.
- **Output finale: solo i quadrati maggiori di 10 → [16, 25].**

```
1.from pyspark.sql import SparkSession
2.
3.# Creazione della sessione Spark
4.spark = SparkSession.builder.appName("Esempio1").getOrCreate()
5.
6.# Creiamo un RDD da una lista
7.numeri = spark.sparkContext.parallelize([1, 2, 3, 4, 5])
8.
9.# Trasformazioni (lazy)
10.quadrati = numeri.map(lambda x: x * x)
11.filtrati = quadrati.filter(lambda x: x > 10)
12.
13.# Azione (trigger dell'esecuzione)
14.risultato = filtrati.collect()
15.
16.print(risultato)
```



Spiegazione

- **createDataFrame** crea un **DataFrame** distribuito con schema (nome, eta).
- **filter(df.eta > 25)** applica una trasformazione su colonna simile a SQL.
- **show()** è un'azione che stampa le righe filtrate.

Output:

```
+-----+----+
| nome|eta|
+-----+----+
|Mario| 30|
| Anna| 40|
+-----+----+
```

```
1.from pyspark.sql import SparkSession
2.
3.# Sessione Spark
4.spark = SparkSession.builder.appName("Esempio2").getOrCreate()
5.
6.# Creiamo un DataFrame da una lista di tuple
7.dati = [("Mario", 30), ("Luca", 22), ("Anna", 40)]
8.df = spark.createDataFrame(dati, ["nome", "eta"])
9.
10.# Selezioniamo solo le persone sopra i 25 anni
11.adulti = df.filter(df.eta > 25)
12.
13.# Visualizziamo il risultato
14.adulti.show()
```



Buon Davante a tutti

