



DataBricks teoria

Python

Databricks è una piattaforma cloud progettata per la gestione, l'elaborazione e l'analisi di grandi quantità di dati, integrando in un unico ambiente attività di Data Engineering, Business Intelligence, Machine Learning e Intelligenza Artificiale.

Nata dagli autori originali di Apache Spark, Databricks introduce il concetto di Lakehouse, un'architettura che combina i vantaggi dei Data Lake e dei Data Warehouse, permettendo di gestire dati strutturati e non strutturati in modo scalabile ed efficiente.



La piattaforma offre strumenti collaborativi basati su notebook, pipeline ETL, query SQL, analisi real-time e modelli AI, consentendo a Data Engineer, Data Scientist e Analyst di lavorare sullo stesso ecosistema.

Uno dei principali punti di forza di Databricks è la capacità di unificare dati, analytics e AI all'interno di una piattaforma aperta e distribuita, riducendo la complessità infrastrutturale e migliorando le performance nell'elaborazione dei Big Data.



Principali caratteristiche di Databricks

- Lakehouse Architecture

Databricks utilizza un'architettura chiamata Lakehouse, che unisce le caratteristiche dei Data Lake e dei Data Warehouse.

Questo approccio permette di archiviare grandi quantità di dati grezzi come in un Data Lake, mantenendo però funzionalità avanzate di gestione, query e ottimizzazione tipiche di un Data Warehouse.

In questo modo è possibile lavorare con dati strutturati, semi-strutturati e non strutturati all'interno di un unico sistema.



Principali caratteristiche di Databricks

- Integrazione con Apache Spark

La piattaforma è basata su Apache Spark, framework distribuito progettato per elaborare enormi quantità di dati in parallelo.

Spark consente elaborazioni molto veloci grazie all'uso della memoria RAM e permette di eseguire ETL, analytics, streaming e Machine Learning su cluster distribuiti.



Principali caratteristiche di Databricks

- Notebook collaborativi

Databricks mette a disposizione notebook interattivi collaborativi, simili a quelli di Jupyter, nei quali più utenti possono lavorare contemporaneamente.

I notebook supportano linguaggi come Python, SQL, Scala e R, consentendo di combinare codice, testo, grafici e visualizzazioni in un unico ambiente condiviso.



Principali caratteristiche di Databricks

- Scalabilità automatica

La piattaforma è pensata per ambienti cloud e supporta l'auto-scaling dei cluster.

Questo significa che le risorse computazionali possono aumentare o diminuire automaticamente in base al carico di lavoro, migliorando prestazioni e ottimizzando i costi infrastrutturali.



Principali caratteristiche di Databricks

- Delta Lake

Una delle componenti fondamentali è Delta Lake, tecnologia che aggiunge affidabilità e gestione avanzata dei dati ai Data Lake.

Delta Lake introduce funzionalità come:

- transazioni ACID;
- versionamento dei dati;
- controllo della qualità;
- gestione dello storico;
- aggiornamenti e cancellazioni efficienti.



Principali caratteristiche di Databricks

- **Supporto al Machine Learning e AI**

Databricks integra strumenti dedicati al Machine Learning e all'Intelligenza Artificiale.

Attraverso librerie come MLflow e framework AI compatibili, gli sviluppatori possono creare, addestrare, monitorare e distribuire modelli di Machine Learning direttamente sulla piattaforma.



Principali caratteristiche di Databricks

- **Elaborazione Real-Time**

La piattaforma supporta lo stream processing, ovvero l'elaborazione di dati in tempo reale.

Questo permette di analizzare flussi continui di dati provenienti da sensori, log, social network o sistemi IoT senza attendere batch di elaborazione.



Strumenti per Data Engineering e gestione dei dati

Uno dei principali è Apache Spark, motore distribuito utilizzato per elaborare grandi volumi di dati in parallelo attraverso cluster.

Per l'organizzazione e l'affidabilità dei dati viene utilizzato Delta Lake, che introduce transazioni ACID, versionamento e controllo della qualità dei dataset.

La piattaforma include inoltre strumenti SQL integrati per creare query, dashboard e report analitici direttamente sul Lakehouse.

Attraverso workflow e pipeline ETL automatizzate, Databricks consente di importare, trasformare e sincronizzare dati provenienti da database, file system, API e sistemi cloud differenti.



Strumenti per AI, Machine Learning e collaborazione

Per l'ambito AI e Machine Learning, Databricks integra strumenti specifici per la creazione e gestione di modelli predittivi.

Tra i più importanti vi è MLflow, utilizzato per tracciare esperimenti, salvare modelli e gestire il ciclo di vita del Machine Learning.

I notebook collaborativi permettono invece a team di Data Scientist e sviluppatori di lavorare insieme utilizzando linguaggi come Python, SQL, Scala e R nello stesso ambiente condiviso.

La piattaforma supporta inoltre librerie di Deep Learning come TensorFlow e PyTorch, offrendo accelerazione hardware tramite GPU per addestrare modelli AI complessi.

Nonostante i numerosi vantaggi, Databricks presenta anche alcune criticità e rischi operativi.

Uno dei principali problemi riguarda la complessità infrastrutturale e architetturale: lavorare con cluster distribuiti, pipeline ETL e sistemi Big Data richiede competenze avanzate in ambiti come cloud computing, gestione dati e ottimizzazione delle performance.

Un utilizzo non corretto delle risorse può inoltre generare costi elevati, specialmente in ambienti cloud con auto-scaling e grandi quantità di dati elaborati continuamente.



Dal punto di vista della sicurezza, la centralizzazione dei dati può aumentare i rischi legati ad accessi non autorizzati, perdita di informazioni sensibili o configurazioni errate dei permessi.

Esistono poi problematiche tecniche legate alla qualità dei dati, alla latenza nello streaming real-time e alla gestione di pipeline molto complesse, che possono causare errori, inconsistenze o rallentamenti nei processi analitici.

Infine, la forte integrazione con ecosistemi cloud e tecnologie specifiche può generare fenomeni di vendor lock-in, rendendo più difficile migrare dati e infrastrutture verso altre piattaforme in futuro.



Buon Davante a tutti

