



Introduzione alla data science

Web dev

La Data Science è una disciplina che si occupa di raccogliere, organizzare, analizzare e interpretare grandi quantità di dati con l'obiettivo di estrarre informazioni utili, individuare pattern nascosti e supportare decisioni più consapevoli.

Non si limita alla semplice lettura dei dati, ma combina statistica, informatica, matematica, programmazione e conoscenza del dominio applicativo per trasformare dati grezzi in conoscenza utilizzabile.

In ambito aziendale, scientifico e tecnologico viene usata per comprendere fenomeni complessi, prevedere comportamenti futuri, automatizzare processi decisionali e migliorare prodotti, servizi e strategie.



La Data Science nasce dall'evoluzione di più aree già esistenti: la statistica, l'analisi dei dati, il data mining e l'informatica.

Con la crescita del web, dei social network, dei dispositivi digitali, dei database aziendali e dei sistemi distribuiti, la quantità di dati disponibili è aumentata enormemente.

Questo ha reso necessario sviluppare nuovi metodi e strumenti per gestire dati sempre più grandi, eterogenei e veloci.

La Data Science moderna si afferma quindi come risposta al bisogno di analizzare i cosiddetti Big Data, sfruttando linguaggi di programmazione come Python o R, database, algoritmi di machine learning, strumenti di visualizzazione e piattaforme cloud.



Raccolta e gestione dei dati

Una delle caratteristiche principali della Data Science è la capacità di raccogliere dati da fonti diverse e organizzarli in modo utilizzabile.

I dati possono provenire da database aziendali, file CSV, API, sensori, social network, applicazioni web o sistemi cloud.

In questa fase è importante comprendere il formato dei dati, la loro qualità, la loro struttura e il loro volume.

Senza una corretta gestione iniziale, anche l'analisi più avanzata rischia di produrre risultati poco affidabili.



Pulizia e preparazione dei dati

I dati reali raramente sono già pronti per essere analizzati: spesso contengono errori, valori mancanti, duplicati, formati incoerenti o informazioni non rilevanti.

La Data Science dedica quindi una parte fondamentale del lavoro alla pulizia e trasformazione dei dati.

Questa fase permette di rendere i dati coerenti, confrontabili e adatti all'analisi statistica o all'addestramento di modelli di machine learning.

È una fase tecnica ma decisiva, perché la qualità dei risultati dipende direttamente dalla qualità dei dati in ingresso.



Analisi e modellazione

La Data Science utilizza tecniche statistiche, algoritmi e modelli matematici per individuare relazioni, tendenze e comportamenti nascosti nei dati.

L'analisi può essere:

- descrittiva, quando serve a capire cosa è successo;
- diagnostica, quando cerca di spiegare perché è successo;
- predittiva, quando prova a stimare cosa potrebbe accadere;
- prescrittiva, quando suggerisce quali azioni intraprendere.

In questa fase possono essere usati anche modelli di machine learning per classificare dati, prevedere valori numerici, riconoscere gruppi simili o automatizzare decisioni.



Interpretazione e comunicazione dei risultati

Una caratteristica essenziale della Data Science è trasformare i risultati tecnici in informazioni comprensibili e utili per prendere decisioni.

Non basta produrre grafici, metriche o modelli: bisogna saper interpretare ciò che emerge dai dati e comunicarlo in modo chiaro a persone tecniche e non tecniche.

Per questo vengono usate visualizzazioni, dashboard, report e storytelling dei dati.



L'obiettivo finale non è solo “fare analisi”, ma generare valore concreto attraverso decisioni più informate, misurabili e basate sui dati.

Andiamo ora vedere le principali tecnologie/linguaggi utilizzati:

Python

Python è uno dei linguaggi più utilizzati nella Data Science grazie alla sua semplicità, alla leggibilità del codice e alla grande quantità di librerie disponibili.

Viene usato per caricare dati, pulirli, analizzarli, creare grafici, addestrare modelli di machine learning e automatizzare processi, librerie come Pandas, NumPy, Matplotlib, Scikit-learn e TensorFlow lo rendono uno strumento centrale in quasi tutto il ciclo di lavoro del data scientist.



R

R è un linguaggio specializzato nell'analisi statistica e nella visualizzazione dei dati. È molto usato in ambito accademico, scientifico, medico, economico e statistico.

Viene impiegato per analisi descrittive, test statistici, modellazione, creazione di grafici avanzati e report interattivi.

Rispetto a Python è spesso scelto quando il lavoro è fortemente orientato alla statistica pura e all'analisi esplorativa.



SQL

SQL è il linguaggio usato per interrogare e gestire database relazionali.

Nella Data Science è fondamentale perché molti dati aziendali sono salvati in database strutturati, come MySQL, PostgreSQL, SQL Server o Oracle, viene utilizzato per estrarre dati, filtrarli, aggregarli, unirli tramite join e prepararli prima dell'analisi.

Anche quando si lavora con strumenti avanzati, la capacità di recuperare correttamente i dati da un database rimane una competenza essenziale.



Pandas

Pandas è una libreria Python dedicata alla manipolazione e all'analisi dei dati tabellari.

Permette di lavorare con strutture simili a tabelle, chiamate DataFrame, e viene usata per leggere file CSV, Excel, JSON o dati provenienti da database.

Con Pandas si possono filtrare righe, selezionare colonne, gestire valori mancanti, raggruppare dati, calcolare statistiche e trasformare dataset grezzi in dati pronti per l'analisi o per il machine learning.



La Data Science viene utilizzata principalmente per trasformare grandi quantità di dati in informazioni utili per prendere decisioni migliori.

In ambito aziendale può servire per analizzare vendite, clienti, costi, processi interni e performance operative, individuando tendenze e anomalie che non sarebbero facilmente visibili con una semplice osservazione manuale.

Per esempio, un'azienda può usare la Data Science per capire quali prodotti vendono di più, quali clienti rischiano di abbandonare un servizio, quali campagne marketing funzionano meglio o quali aree produttive generano sprechi.



Un altro caso d'uso molto importante riguarda la previsione e l'automazione intelligente.

Attraverso modelli statistici e algoritmi di machine learning, la Data Science permette di stimare eventi futuri o supportare decisioni automatiche: prevedere la domanda di mercato, classificare email come spam, rilevare frodi bancarie, suggerire prodotti personalizzati, diagnosticare possibili guasti nei macchinari o analizzare dati sanitari.

In questo senso, la Data Science non si limita a descrivere ciò che è già accaduto, ma aiuta a costruire sistemi capaci di anticipare problemi, ottimizzare risorse e migliorare servizi in modo continuo



Una delle principali problematiche della Data Science riguarda la qualità dei dati. I dati reali spesso sono incompleti, duplicati, incoerenti o raccolti in formati diversi.

Prima di poterli analizzare, è necessario pulirli, normalizzarli e verificarne l'affidabilità. Se i dati di partenza sono errati o poco rappresentativi, anche i modelli più avanzati produrranno risultati sbagliati o poco utili.

Un'altra difficoltà importante è la gestione del volume e della complessità dei dati.

In molti contesti aziendali i dati provengono da fonti diverse, come database, file, API, sensori, applicazioni web o sistemi cloud, questo rende complessa l'integrazione delle informazioni e richiede strumenti adeguati per archiviare, elaborare e interrogare grandi quantità di dati.



Una problematica centrale è anche l'interpretabilità dei risultati, un modello può produrre una previsione corretta, ma se non è chiaro perché ha preso una certa decisione, può diventare difficile fidarsi del risultato o usarlo in contesti critici.

Questo è particolarmente importante in settori come sanità, finanza e risorse umane, dove le decisioni automatiche possono avere conseguenze rilevanti sulle persone.

Infine, la Data Science deve affrontare problemi legati a privacy, sicurezza ed etica. I dati possono contenere informazioni personali o sensibili, quindi devono essere gestiti rispettando normative, autorizzazioni e principi di responsabilità; Inoltre, se i dati contengono pregiudizi o squilibri, anche i modelli possono replicare o amplificare quei bias, generando decisioni ingiuste o discriminatorie.



Figure lavorative principali

Il Data Scientist è la figura più rappresentativa dell'ambito.

Si occupa di analizzare dati, costruire modelli statistici e sviluppare algoritmi di machine learning per estrarre informazioni utili.

Deve conoscere programmazione, statistica, matematica, strumenti di analisi e il contesto applicativo in cui lavora.

Il suo compito non è solo produrre modelli, ma trasformare i dati in valore concreto per l'azienda.



Il Data Analyst

si concentra soprattutto sull'analisi descrittiva dei dati e sulla produzione di report, dashboard e indicatori.

Lavora spesso con strumenti come SQL, Excel, Power BI, Tableau o Python, e aiuta aziende e team a comprendere cosa sta accadendo attraverso numeri, grafici e metriche.

È una figura fondamentale per supportare decisioni operative e strategiche basate sui dati.



Il Data Engineer

si occupa della parte infrastrutturale e tecnica del ciclo dei dati. Progetta pipeline, sistemi di raccolta, archiviazione e trasformazione dei dati, lavorando con database, cloud, sistemi distribuiti e strumenti Big Data.

Il suo ruolo è garantire che i dati siano disponibili, aggiornati, organizzati e accessibili per Data Analyst, Data Scientist e altri reparti aziendali.



Il Business Intelligence Specialist

lavora sulla creazione di sistemi di analisi e visualizzazione dei dati per il business. Si occupa di dashboard, KPI, report direzionali e strumenti che permettono ai manager di controllare l'andamento aziendale.

È una figura vicina al Data Analyst, ma con un focus più marcato sugli strumenti di reporting, sulla misurazione delle performance e sul supporto alle decisioni aziendali.



Buon Davante a tutti

